Базы данных

Курс лекций

Учебное пособие для студентов

2026

Оглавление

1. Введение в базы данных 3

2. Реляционная модель 9

3. Язык SQL 15

4. Нормализация 21

5. Транзакции 27

6. Индексы 33

Заключение 39

Список литературы 40

1. Введение в базы данных

База данных — организованная совокупность данных, которые хранятся и используются в вычислительной системе. Система управления базами данных (СУБД) — комплекс программ для создания баз данных, управления ими и доступа к данным.

До появления СУБД данные хранились в отдельных файлах каждого приложения. Это приводило к дублированию данных и к зависимости программ от формата файлов. СУБД обеспечивает независимость данных: приложения работают с логическим представлением, а не с физическим размещением данных.

Архитектура ANSI/SPARC выделяет три уровня: внешний (представления отдельных пользователей), концептуальный (логическая схема всей базы данных) и внутренний (физическое хранение данных).

По модели данных различают иерархические СУБД (данные образуют дерево, пример — IBM IMS), сетевые (стандарт CODASYL), реляционные и NoSQL-системы: документные, «ключ — значение», колоночные и графовые.

Основные функции СУБД: управление данными во внешней памяти, управление буферами оперативной памяти, управление транзакциями, журналирование и восстановление после сбоев, поддержка языков баз данных.

Язык SQL делится на подмножества: DDL — определение данных (CREATE, ALTER, DROP), DML — манипулирование данными (SELECT, INSERT, UPDATE, DELETE) и DCL — управление доступом (GRANT, REVOKE).

2. Реляционная модель

Реляционную модель данных предложил сотрудник IBM Эдгар Кодд в 1970 году в статье «A Relational Model of Data for Large Shared Data Banks».

Отношение — множество кортежей с одинаковым набором атрибутов. В таблице отношению соответствует сама таблица, кортежу — строка, атрибуту — столбец. Число атрибутов называют степенью отношения, число кортежей — его мощностью.

Домен — множество допустимых значений атрибута. Значения атрибутов атомарны: в ячейке хранится одно значение, а не список значений.

Потенциальный ключ — минимальный набор атрибутов, однозначно определяющий кортеж. Один из потенциальных ключей выбирают первичным. Первичный ключ не может содержать NULL.

Внешний ключ — атрибут или набор атрибутов, значения которых ссылаются на первичный ключ другого отношения. Ограничение ссылочной целостности запрещает ссылки на несуществующие кортежи.

Основные операции реляционной алгебры: выборка отбирает кортежи по условию, проекция оставляет часть атрибутов, соединение объединяет кортежи двух отношений по условию. Кроме них есть объединение, пересечение, разность и декартово произведение.

3. Язык SQL

Предложения запроса SELECT логически обрабатываются в порядке FROM, WHERE, GROUP BY, HAVING, SELECT, ORDER BY. Поэтому псевдоним столбца, заданный в SELECT, нельзя использовать в WHERE.

WHERE фильтрует строки до группировки, а HAVING — группы после неё. Агрегатные функции допустимы в HAVING, но не в WHERE.

Агрегатные функции SQL: COUNT, SUM, AVG, MIN и MAX. COUNT(*) считает все строки, а COUNT(столбец) — только строки, где значение столбца не NULL.

INNER JOIN возвращает только пары строк, удовлетворяющие условию соединения. LEFT JOIN возвращает все строки левой таблицы и дополняет отсутствующие значения правой таблицы NULL. FULL OUTER JOIN возвращает все строки обеих таблиц.

NULL означает отсутствующее или неизвестное значение. Сравнение с NULL через знак равенства даёт UNKNOWN, поэтому для проверки используют IS NULL и IS NOT NULL.

Коррелированный подзапрос ссылается на столбцы внешнего запроса и логически выполняется для каждой его строки. Оператор EXISTS проверяет, возвращает ли подзапрос хотя бы одну строку.

4. Нормализация

Нормализация — приведение схемы базы данных к нормальным формам, чтобы устранить избыточность и аномалии вставки, обновления и удаления.

Функциональная зависимость A → B означает, что каждому значению атрибута A соответствует ровно одно значение атрибута B.

Отношение находится в первой нормальной форме (1НФ), если все его атрибуты атомарны и в нём нет повторяющихся групп.

Отношение находится во второй нормальной форме (2НФ), если оно в 1НФ и каждый неключевой атрибут зависит от всего первичного ключа, а не от его части. Частичная зависимость возможна только при составном ключе.

Отношение находится в третьей нормальной форме (3НФ), если оно во 2НФ и неключевые атрибуты не зависят от ключа транзитивно. В нормальной форме Бойса — Кодда левая часть любой нетривиальной функциональной зависимости — суперключ.

Денормализация — сознательное введение избыточности ради ускорения чтения, например в хранилищах данных. Её цена — усложнение поддержки согласованности данных.

5. Транзакции

Транзакция — последовательность операций, выполняемая как единое целое: либо все изменения фиксируются командой COMMIT, либо все отменяются командой ROLLBACK.

Свойства транзакций ACID: атомарность (всё или ничего), согласованность (переход из одного допустимого состояния в другое), изоляция (параллельные транзакции не влияют друг на друга) и долговечность (зафиксированные изменения сохраняются после сбоя).

Аномалии параллельного доступа: грязное чтение — чтение незафиксированных изменений другой транзакции; неповторяемое чтение — повторное чтение строки даёт другое значение; фантомное чтение — повторный запрос возвращает новые строки.

Стандарт SQL определяет уровни изоляции READ UNCOMMITTED, READ COMMITTED, REPEATABLE READ и SERIALIZABLE. Уровень SERIALIZABLE исключает все три аномалии.

Разделяемая блокировка ставится для чтения и совместима с другими разделяемыми; исключительная ставится для записи и несовместима ни с какими. Взаимоблокировка возникает, когда две транзакции ждут ресурсы друг друга; СУБД обнаруживает её и откатывает одну из транзакций.

При журнале упреждающей записи (WAL) изменение сначала записывается в журнал и только потом в файлы данных. После сбоя СУБД повторяет зафиксированные транзакции и отменяет незафиксированные. MVCC хранит несколько версий строки, чтобы читатели не блокировали писателей.

6. Индексы

Индекс — вспомогательная структура, ускоряющая поиск строк по значениям столбцов. Цена индекса — дополнительная память и замедление вставки и обновления.

B-дерево — сбалансированное дерево и самый распространённый тип индекса. Оно поддерживает поиск по равенству и по диапазону за логарифмическое время.

Хеш-индекс ускоряет только поиск по равенству и не подходит для поиска по диапазону и сортировки.

Составной индекс по столбцам (a, b) используется для условий по a или по a и b, но, как правило, не для условий только по b. Это правило левого префикса.

Кластерный индекс определяет физический порядок строк таблицы, поэтому у таблицы может быть только один кластерный индекс.

План выполнения запроса показывает команда EXPLAIN. Оптимизатор выбирает между последовательным сканированием и индексом по статистике; при низкой селективности условия полное сканирование бывает быстрее индекса.

Заключение

Курс охватывает путь от общих понятий баз данных через реляционную модель и SQL к проектированию схем, транзакциям и индексам. Эти темы составляют основу работы с любой реляционной СУБД.

Список литературы

1. Дейт К. Дж. Введение в системы баз данных.

2. Кузнецов С. Д. Основы баз данных.

3. Codd E. F. A Relational Model of Data for Large Shared Data Banks // Communications of the ACM. 1970.